

天津理工大学学报
Journal of Tianjin University of Technology
ISSN 1673-095X, CN 12-1374/N

《天津理工大学学报》网络首发论文

题目: 基于改进 YOLO11n 的多种类杂草检测模型
作者: 王兴伟, 李霞, 朱志航, 秦涛, 朱航, 罗安齐
收稿日期: 2025-12-16
网络首发日期: 2026-03-03
引用格式: 王兴伟, 李霞, 朱志航, 秦涛, 朱航, 罗安齐. 基于改进 YOLO11n 的多种类杂草检测模型[J/OL]. 天津理工大学学报.
<https://link.cnki.net/urlid/12.1374.N.20260303.1018.002>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于改进 YOLO11n 的多种类杂草检测模型

王兴伟^{1,2}, 李霞^{1,2*}, 朱志航^{1,2}, 秦涛^{1,2}, 朱航^{1,2}, 罗安齐^{1,2}

(1. 天津理工大学 天津市先进机电系统设计与智能控制重点实验室, 天津 300384;

2. 天津理工大学 机电工程国家级实验教学示范中心, 天津 300384)

摘要: 针对田间杂草处理中资源浪费问题, 为实现选择性精准除草, 提出一种改进的 YOLO11n (you only look once version 11n) 杂草检测算法。该方法在网络主干中使用下采样模块 Adown 替代普通卷积, 以增强特征提取能力; 在颈部引入动态上采样器 Dysample (dynamic sample) 替换 Upsample, 提升灵活性并降低 GPU 内存占用; 同时采用基于轻量级卷积 (grouped and shuffled convolution, GSConv) 设计的 slim-neck 模块, 优化检测效率。实验结果表明, 该模型参数量为 2.25M, 在精确率、召回率、F1 分数和 mAP50 (Mean Average Precision at IoU=0.5) 上分别达到 94.7%、91.6%、93.1% 和 96.0%, 相比原 YOLO11n 分别提升 1.2%、2.8%、2.0% 和 1.7%, 同时参数量减少 13.3%。所提算法在精度、速度与鲁棒性方面均表现优异, 适用于除草机器人等移动平台, 为田间杂草的实时准确识别提供了有效解决方案。

关键词: 杂草检测; 轻量化模型; 网络改进; 智能识别

中图分类号: S24 **文献标识码:** A

Detection model for multiple weed species based on improved YOLO11n

WANG Xingwei^{1,2}, LI Xia^{1,2*}, ZHU Zhihang^{1,2}, QIN Tao^{1,2}, ZHU Hang^{1,2}, LUO Anqi^{1,2}

(1. Tianjin Key Laboratory for Advanced Mechatronic System Design and Intelligent Control,

Tianjin University of Technology, Tianjin 300384, China;

2. National Demonstration Center for Experimental Mechanical and Electrical Engineering Education, Tianjin University of Technology, Tianjin 300384, China)

Abstract: To address the issue of resource wastage in the management of field weeds and to achieve selective and precise weeding, we propose an improved you only look once version 11n (YOLO11n) weed detection algorithm. This method employs a downsampling module, Adown, in the network backbone to replace conventional convolutions, thereby enhancing the feature extraction capability. Additionally, a dynamic upsampler, Dysample (dynamic sample), is introduced in the neck of the network to replace the standard Upsample, increasing flexibility while reducing GPU memory usage. Furthermore, a slim-neck module designed based on the lightweight convolution GSConv (grouped and shuffled convolution) is adopted to optimize detection efficiency. Experimental results show that the model has 2.25M parameters, with a precision of 94.7%, recall of 91.6%, F1 score of 93.1%, and mAP50 (Mean Average Precision at IoU=0.5) of 96.0%. These metrics represent improvements of 1.2%, 2.8%, 2.0%, and 1.7%, respectively, compared to the original YOLO11n. At the same time, the parameter count is reduced by 13.3%. The proposed algorithm demonstrates excellent performance in terms of precision, speed, and robustness, making it suitable for applications in weed removal robots and other mobile platforms, providing an effective solution for real-time and accurate weed identification in the field.

Key words: weed detection; lightweight model; network improvement; intelligent recognition

杂草是在农田中自然生长的原生植物, 杂草的处理是推动农业大规模发展的决定性因素。杂草与作物

竞争水分、空气、光照和空间等资源, 从而造成农作物的产量损失^[1-2]。某些杂草同时还会产生释放一定化

学抑制物质,对作物生长产生干扰,影响其正常生长发育^[3]。在普通农田中,由于杂草的存在而造成的作物损失率大约在 23%到 44%之间^[4]。因此,进行有效的杂草控制势在必行。然而,由于田间环境的复杂性,当前对于农田中不同种类杂草的防治大多依赖于统一的除草方法和剂量,这导致了能源浪费、环境污染以及除草效果不理想等一系列问题。在此前的一项研究中,LAURSEN 等^[5]提出了一种算法,能够估算玉米田中双子叶杂草与单子叶作物的相对比例,以减少除草剂的使用。他们的研究表明,选择性使用除草剂可以减少 65%的使用量,而其生物效果却没有损失。因此,针对不同种类杂草选择对相应的除草剂是一种可行的方法,而要实现以上目标需解决的关键问题就是实现田间杂草类型的准确区分。

近年来,深度学习因其卓越的拟合与泛化能力,对复杂数据的高度适应性以及支持端到端学习^[6]等优势,已在图像处理^[7]、语音识别^[8]和自然语言的处理^[9]等多个领域超越了传统机器学习方法。在智慧农业领域,深度学习被广泛应用于除草机器人技术,通过集成多种传感器^[10]和末端执行器的协同工作^[11-12],实现了对各类田间杂草的自主识别与定位^[13]。其中,YOLO (you only look once)作为一种高效的目标检测算法,因其简洁的模型结构、适配硬件加速的能力以及在多种硬件平台上的适应性得到了诸多学者的青睐^[14]。SHAO 等^[15]提出了一种改进的深度学习模型 GTCBS-YOLOv5s,并将该模型应用于稻田内六种杂草的识别中。最终,该模型对测试集的平均识别精度 (mAP50) 达到了 91.1%,识别速度达到 85.7FPS,与现有模型相比,GTCBS-YOLOv5s 具有精度高、鲁棒性强、推理速度快以及更加轻量化等优点。SUN^[16]等人针对杂草多目标识别和可移植性的要求,提出了 YOLO-WEED 杂草识别模型,该模型最终的平均准确率达到 92.5%,模型的参数量减少了 39.4%,实现了 Jetson 移动的终端多目标检测的模型优化和部署。NIU 等^[17]提出了一种改进的轻量级算法 YOLOv8-ECFS,并将其运用于之智能喷洒系统中来管理杂草,及时调整除草剂的种类和剂量。测试集结果表明,该模型的 mAP50 提升了 1.3%,GFLOPs 和模型大小分别减少了 11.1G 和 9.1MB,确保了识别精度

和轻量级性能。FAN 等^[18]提出了一种名为 YOLO-WDNet 的轻量级和高精度的深度学习模型,用于检测棉田中的杂草。与原模型相比,该模型在检测精度提高的同时,参数量降低了 82.3%,模型占用内存减少了 91.6%,GFLOPs 减少了 82.3%,并成功部署在移动地面机器人上进行了实地测试。

以上研究表明,YOLO 算法在农田杂草分类识别任务中展现了巨大的潜力。因此,本文提出了一种基于 YOLO11n 的改进深度学习模型,旨在提高杂草检测的精度,并使其更易于在移动设备上部署。本文将 Adown 下采样模块、Dysample 上采样结构以及 Slim-neck 模块集成到改进的 YOLO11n 模型当中,构建了 YOLO11-ADS (模型改进后的命名) 模型。该模型通过精细化的特征学习,提升了对不同种类杂草的区分能力,从而增强了模型的检测精度。研究的创新之处在于设计了一种轻量化的多类别杂草检测模型,既能快速、准确地识别杂草种类及其位置,又具备良好的边缘计算适应性,便于在实际农业应用中部署。

1 实验材料

1.1 数据获取与处理

本文采用开源的杂草数据集 CottonWeedDet12^[19]作为数据集,该数据集使用智能手机与数字彩色摄像头进行拍摄,拍摄地点为密西西比州立大学研究农场的棉田。为了确保图像的多样性,以提高模型的鲁棒性,图像在自然田间光照条件下以及不同天气条件(如晴天、阴天和多云)下采集,涵盖了杂草生长的不同阶段和不同田间位置。最终,该数据集共收集了具有 9370 个边界框注释的 5648 个图像,主要包括了 12 个杂草类别,其中涵盖了阔叶杂草、禾本科杂草、草本杂草等多种形态类别。为了保证数据的多样性和各类杂草数量的均衡,防止过拟合,通过旋转、亮度调整和高斯噪声添加等操作对原数据集的图像进行增强。经过数据扩充后,最终数据集由 6800 张图像组成,并以 7:2:1 的比例将其划分为训练集、验证集和测试集,各部分之间相互独立,无重复样本。

1.2 YOLO11n 网络模型

在各种物体检测算法中,YOLO 框架因其在速度和准确性方面的显著平衡而脱颖而出,能够快速、可

靠地识别图像中的物体, 被广泛应用在目标检测任务中。由 Ultralytics 开发的 YOLO11 模型, 主要有主干、颈部和头部组成, 如图 1 所示。YOLO11 的主干采用了 CSPDarknet-53 架构, 由 CBS、C3K2、SPPF 以及 C2PSA 组成。其中, CBS 模块主要执行卷积运算, 包括卷积 (conv)、批量归一化 (BN) 和 SiLU 激活函数。头部模块在解耦头的分类检测头中增加了两个深度可分离卷积, 大幅减少了网络的计算量

与参数量, 减少了冗余计算, 提高了计算效率。

根据网络的宽度和深度, YOLO11 可以分为五个网络: YOLO11n, YOLO11s, YOLO11m, YOLO11l 和 YOLO11x。随着这些模型的准确性提高, 计算复杂性和参数数量也会增加, 以满足不同的场景需求。针对移动除草平台的部署需求, 选择 YOLO11n 作为杂草目标检测与分类的轻量级基础模型。




图 1 YOLO11 的模型结构图

Fig.1 The model architecture diagram of YOLO11

2 研究方法

2.1 改进模型的网络结构

本文提出的网络改进模型如图 2 所示。为了适应田间的复杂环境, 对 YOLO11n 进行了针对性的改进。首先, 针对卷积网络难以提取全局信息的问题, 采用了下采样模块 Adown 替换主干网络中的普通卷积来提高信息提取的质量, 实现了精度与效率

的同步提高。其次, 在网络的颈部, 集成了 Dysample 动态上采样器, 该方法采用高效的点采样取代原先的传统平均采样, 增加了模型的灵活性, 从而能够更加精确的定位目标物体的位置。最后, 添加基于轻量级卷积 GSConv 设计的 slim-neck, 该模块在精度和速度之间实现了出色的平衡, 有效提升了神经网络的性能与计算效率。




图 2 YOLO11-ADS 的模型结构图

Fig.2 The model architecture diagram of YOLO11-ADS

2.1.1 Adown 下采样模块

Adown 是 YOLOv9 中采用的一种用于下采样操

作的卷积块,如图3所示。该模块的核心思想是通过通道拆分将输入特征分解为两个独立分支,并采用不同的自适应下采样策略进行处理,最终将提取到的特征进行融合。首先,对输入的张量信息应用一个平均池化操作进行初步处理。接下来采用两个并行分支进行信息处理,一个分支采用核大小为 3×3 、步长为2的标准卷积层进行处理,另一个分支则先进行最大池化处理,以保留更显著的局部细节特征,其后接一个 1×1 卷积层用于进行通道维度的线性组合与变换。最后,两个分支在通道维度上进行拼接,形成该模块的最终输出。




图3 Adown网络结构图

Fig.3 The network architecture diagram of Adown

该结构在显著降低计算复杂度和参数量的同时,保持了较强的表征能力。因此,该模块非常适用于构建高效的轻量级神经网络,在杂草检测任务中作为基础下采样组件,实现了精度与效率的良好平衡。

2.1.2 Dysample 上采样模块

YOLO11 的颈部特征融合网络的上采样模块使用了最近邻插值法,该方法应用固定的规则对低分辨率特征进行插值,不能有效地解读特征映射中的语义含义。本文采用了一种基于动态点采样的算子 Dysample,如图4所示,该方法先通过上采样的采样点生成器结构生成采样集,后利用生成的采样器进行特征图重构。具体操作步骤如下:首先,输入大小为 $H\times W\times C$ 的低分辨率特征图 X 。接着,该特征图通过线性层1且通过大小为 0.5δ 的动态范围调整因子生成一个偏移,该偏移与特征图通过线性层2生成的另一个偏移相乘,输出大小为 $H\times W\times 2S^2$ 的

总特征偏移。然后,总特征偏移通过像素混洗生成偏移 O ,与原始采样网络 g 相加以生成大小为 $SH\times SW\times 2g$ 的所需的动态采样器 S 。最后,原始特征输入 X 和动态采样器 S 通过网格采样操作重新组织所需的特征位置信息,最终获得预测特征图 X' 。具体计算过程如式(1)~(3)^[20]:

$$O = \text{linear}(X) \quad (1)$$

$$S = G + O \quad (2)$$

$$X' = \text{grid sample}(X, S) \quad (3)$$

其中,linear是指线性操作,grid sample是指网络采样操作。

这种动态点采样方法能够有效地将低分辨率的特征图上采样到更高分辨率,这对杂草识别至关重要。高分辨率特征图还能够更好地保留和呈现密集杂草的细节,提高识别精度。此外,Dysample上采样模块摆脱了对定制CUDA包的依赖,极大地优化了计算资源的消耗,在延迟、训练内存、训练时间、GFLOPs和参数数量等方面展现出了显著的优势。这一优化使得该方法能够在资源受限的设备上高效运行,从而非常适合本文的研究任务。




图4 Dysample网络结构图

Fig.4 The network architecture diagram of Dysample

2.1.3 Slim-neck 模块

为了进一步对模型进行轻量化并且提高其精度,研究采用了 Slim-neck^[21]对 YOLO11 的颈部进行了网络替换。具体来说,采用 GSConv 代替颈部网络中的普通卷积,并使用由一次性聚合策略设计的 VoV-GSCSP 模块代替颈部网络中的 C3k2 模块。其中,GSConv 模块的引入主要是以较低的时间复杂度尽可能的保留通道之间的信息连接,如图5所示,该模块首先将通道密集卷积(the channel-dense convolutional, SC)生成的特征渗透到深度可分离卷积(the depth-wise separable convolutional, DSC)生成

的特征的每个部分, 并且允许来自 SC 的信息通过在不同信道上均匀地交换本地特征信息而完全混合到 DSC 的输出中, 接着通过混洗操作得到最终输出。而 GS bottleneck 则用于增强非线性表达和信息复用, 其具体结构如图 6 所示, 主要通过串联两个 GSConv 模块并与普通卷积相加得到输出。接着, 由 GS bottleneck 与普通卷积进行残差连接, 最终构成 VoV-GSCSP 模块, 其具体结构如图 7 所示。Slim-neck 模块主要作用于网络的颈部, 而网络的颈部主要用于杂草图像的特征融合和处理, 通过在 YOLO11 的颈部引入以上模块, 使网络提高了杂草的检测精度, 减少冗余的信息和不必要的计算, 在提高各类杂草的整体检测效率的同时又保持了轻量化, 适合在除草机器人移动平台上部署。




图 5 GSConv 网络结构图

Fig.5 The network architecture diagram of GSConv




图 6 GS bottleneck 网络结构图

Fig.6 The network architecture diagram of GS-Bottleneck




图 7 VoV-GSCSP 网络结构图

Fig.7 The network architecture diagram of VoV-GSCSP

2.2 实验环境及评价指标

2.2.1 超参数设置和操作环境

本实验主要配置为系统: Windows10 版本, 开发平台: PyCharm, CPU: 12tn Gen Intel(R) Core(TM) i5-12400F, GPU: Nvidia GeForce GTX 4060ti, 使用 python3.10 和 CUDA12.4 来训练模型。在训练过程中, 超参数设置如下: epoch 值为 200, batch size

为 16 optimizer 为 SGD learning rate 为 0.01, worker 为 8。

2.2.2 评价指标

为了评价模型的检测性能, 我们采用精确率 (Precision)、召回率 (Recall)、F1 分数以及 mAP50 作为其评价指标。

精确率表示预测为真的正例样本与全部预测为真的样本的比值, 计算过程如式 (4) 所示:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (4)$$

式中, TP (true positive) 表示模型将正例正确地预测为正例的数量。FP (false positive) 表示模型将负例错误地预测为正例的数量。

召回率表示预测为真的正例占全部实际为正例的样本的比例, 计算过程如式 (5) 所示:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (5)$$

式中, FN (false negative) 表示模型将正例错误地预测为负例的数量。

F1 分数反应了模型的整体性能, F1 分数越大, 说明模型的质量越高, 计算过程如式 (6) 所示:

$$F1 = \frac{2TP}{2TP + FP + FN} \quad (6)$$

平均精度 (average precision, AP) 是对象检测算法的常用度量。它通常被定义为精确度-召回率曲线下的面积, 其值的范围为 0 至 1。因此, AP 值越高, 则分类器的性能越好, 计算过程如式 (7) 所示:

$$AP = \int_0^1 P(R) dR \quad (7)$$

平均精度均值 (mean average precision, mAP) 是常用的模型性能评价指标, 用于衡量模型在不同类别和不同阈值 (intersection over union, IoU) 下的平均精度, 计算过程如式 (8) 所示:

$$mAP = \frac{1}{c} \sum_{i=1}^c AP_i \quad (8)$$

式中, c 表示类别数量。mAP50 是指 IoU 阈值为 50.0% 时所有类别的平均 AP 值, 而 mAP50-95 是指 IoU 阈值为 50.0%-95.0% 时的平均 AP 值。AP 值越高, 代表模型对杂草目标的识别精度越高。

此外, 为了对模型的复杂程度和计算速度进行评价, 本文还采用了 GFLOPs 以及参数量等评价指

标。参数量代表检测模型所需的参数总数, GFLOPs 是指每秒十亿次浮点运算, 表示模型每秒可以执行的浮点运算量, 较大的 GFLOPs 通常意味着更强的计算能力, 但较小的 GFLOPs 可以高效且快速的部署模型。通常来说, GFLOPs 越小, 参数量越少, 模型更易于部署和实际应用。

3 结果与讨论

3.1 消融实验

为了全面评估改进模型的性能, 进行了消融实验, 实验结果如表 1 所示。其中, “√”表示包含对应模块, 而“×”表示排除该模块。通过对不同参数配置的比较, 能够系统地分析模型各组成部分对性能的影响。通过数据对比可以观察到, 使用 YOLO11 作为基准网络, 在添加 Adown 下采样模块, Dysample 上采样结构以及 Slim-neck 模块之后, 模型得到了不同程度的改善, 从而证明每个模块都有助于提高模型性能。添加了 Adown 下采样模块后, 杂草检测的准确率、召回率和 mAP50 分别提高

了 0.9%, 0.7%和 1.1%, 模型的参数量也下降了 16.8%。表明该模块在对杂草位置以及杂草种类的识别性能进行提升的同时, 也保持了检测的效率, 实现了网络的轻量化。用 Dysample 替换掉原网络的上采样结构后, 在参数量没有明显上升的情况下, 使网络的精确率、mAP50 和 mAP50-95 分别提高了 1.1%、0.8%和 0.6%。这一结果表明, Dysample 模块在不增加计算负担的同时, 能够有效提升网络对杂草信息的捕捉能力。在网络的颈部采用 Slim-neck 模块进行网络替换, 替换后的网络召回率、mAP50 和 mAP50-95 也都分别提高了 1.4%, 0.7%和 0.4%。

综合消融实验结果, 可以看出, 改进后的 YOLO11-ADS 模型相较于原始 YOLO11 模型在精确率、召回率和 mAP50 分别提升了 1.2%、2.8%和 1.7%, 参数量减少了 13.3%, GFLOPs 下降了 21.5%, 表明了该模型在定位杂草位置时更加准确, 能够更好的提取到有用的杂草特征, 同时也能保持较高的检测效率, 达到了良好的性能与计算效率之间的平衡, 证明了该网络的优越性。

表 1 消融实验结果

Tab.1 Ablation experiment results

YOLO11n	Adown	Dysample	Slim-neck	精确率(%)	召回率(%)	F1 分数(%)	mAP50 (%)	参数量 (M)
√	×	×	×	93.5	88.8	91.1	94.3	2.59
√	√	×	×	94.4	89.5	91.9	95.4	2.16
√	×	√	×	94.6	88.9	91.7	95.1	2.60
√	×	×	√	93.7	90.2	91.9	95.0	2.52
√	√	√	×	94.8	88.9	91.8	95.6	2.26
√	√	×	√	94.6	90.4	92.5	95.5	2.23
√	×	√	√	95.1	89.7	92.3	95.3	2.53
√	√	√	√	94.7	91.6	93.1	96.0	2.25

3.2 对比实验

在本节中, 在相同的数据集以及运行环境下, 将 YOLO11-ADS 模型与几个经典的轻量化网络模型相比较, 包括 YOLOv5n、YOLOv5s、YOLOv8n、YOLOv8s、YOLOv10n、YOLO11n、以及 YOLO11s。表 2 列出了各个模型对杂草检测的评价指标。其中, YOLO11s 的 mAP50 和 F1 分数也达到了不错的效果, 分别为 92.8%和 95.8%, 但与 YOLOv8s 和 YOLOv5s 一样, 其模型的参数量以及 GFLOPs 尺寸

较大, 不符合轻量化的标准, 难以在边缘嵌入式设备上部署。YOLOv5n、YOLOv8n、YOLOv10n 和 YOLO11n 都具有较小的参数量以及 GFLOPs, 可以确保模型的轻量化, 且易于在嵌入式设备上部署, 但它们的精度较低, 不能很好的保证杂草的识别精度。而本研究所提出的模型 YOLO11-ADS 不仅具有较高的精确度、F1 分数以及 mAP50, 在参数量与 GFLOPs 方面相较于其他型号的 YOLO 模型也具有优势, 突出了其在杂草检测任务中的卓越性能。综

合以上情况可以看出, YOLO11-ADS 模型在识别精度与轻量化的平衡设计上具有更出色的表现, 适合在实际环境中部署。

表 2 对比实验结果

Tab.2 Comparison experiment results

模型	精确率 (%)	召回率 (%)	F1 分数 (%)	mAP50 (%)	参数量 (M)	GFLOPs (G)
YOLOv5n	92.9	87.5	90.1	93.7	2,51	7.2
YOLOv5s	93.9	90.8	92.3	95.2	9,12	23.9
YOLOv8n	93.9	86.0	89.8	93.9	3,01	8.2
YOLOv8s	94.5	88.7	91.5	95.6	11,14	28.7
YOLOv10n	92.7	88.5	90.6	94.0	2,71	8.4
YOLO11n	93.5	88.8	91.1	94.3	2,59	6.5
YOLO11s	94.0	91.7	92.8	95.8	9,43	21.6
YOLO11-ADS	94.7	91.6	93.1	96.0	2,25	5.1

3.3 改进模型的视觉检测效果

为了展示 YOLO11-ADS 模型的视觉检测效果, 本节使用测试集中的图像来比较 YOLO11n 和 YOLO11-ADS 模型的检测结果, 如图 8 所示。在如图 8 (a) 所示的杂草图像背景简单且目标无相互重叠的场景中, YOLO11-ADS 不仅实现了高置信度的准确检测, 还能有效识别边缘信息不完整的杂草目

标; 相比之下, YOLO11n 则出现了漏检现象。如图 8 (b) 所示, 在杂草存在相互遮挡或重叠的复杂场景中, 改进后的模型能够检测到边缘目标, 即使是对被遮挡的小目标杂草也能实现准确检测。在杂草密集生长区域, 如图 8 (c) 所示, YOLO11-ADS 能够准确分辨各类杂草, 且对多数类别的杂草检测精度高于 YOLO11n。




图 8 改进前后模型的杂草识别效果对比图

Fig.8 The comparison of weed identification effectiveness between the models before and after improvement

由此可见, YOLO11-ADS 模型能够有效地识别和区分各类杂草。这是因为 YOLO11-ADS 使用了 Adown 下采样模块替换了网络主干中的普通卷积, 提高了网络对于复杂目标提取特征的质量, 可以捕获到更多的杂草信息。在网络的颈部结构中, 模型

采用了 Dysample 替换 Upsample, 增强了网络滤除不必要背景特征的能力, 使得杂草漏检和误检的情况减少。综上所述, YOLO11-ADS 在复杂田间环境中杂草分类检测方面表现出优异的性能。

4 结 论

本文针对传统除草方法中采用统一除草方式所导致的能源浪费问题,提出了一种改进的YOLO11-ADS模型,旨在通过精准分类不同种类的杂草,实现针对性除草策略,优化除草作业过程,降低能源消耗。该算法根据不同杂草种类的特性,选择合适的除草方式,避免盲目施用单一方法,提升能源利用效率。在YOLO11n中集成Adown下采样模块、Dysample上采样算子和Slim-neck模块,提高模型的整体性能与杂草检测效果。实验结果表明,YOLO11-ADS在杂草检测中的精确率、召回率、F1分数和mAP50分别达到了94.7%、91.6%、93.1%和96.0%,与原始模型YOLO11n相比,分别提高了1.2%、2.8%、2.0%和1.7%。与此同时,参数量减少了13.3%,GFLOPS下降了21.5%。与其他模型相比,该模型也在确保高精度的同时达到了轻量化设计的要求,适合部署到嵌入式设备中,并与除草机器人相结合,提高除草效率,推动农业除草技术向更加智能化、精细化的方向发展。

参 考 文 献

- [1] VIJAYAKUMAR V, AMPATZIDIS Y, SCHUELLER J K, et al. Smart spraying technologies for precision weed management: a review[J]. Smart Agricultural Technology, 2023, 6: 1-16.
- [2] G C S, ZHANG Y, KOPARAN C, et al. Weed and crop species classification using computer vision and deep learning technologies in greenhouse conditions[J]. Journal of Agriculture and Food Research, 2022, 9: 1-15.
- [3] ADHINATA FD, WAHYONO, SUMIHARTO R. A comprehensive survey on weed and crop classification using machine learning and deep learning[J]. Artificial Intelligence in Agriculture, 2024, 13: 45-63.
- [4] AYOUB SHAIKH T, RASOOL T, RASHEED LONE F. Towards leveraging the role of machine learning and artificial intelligence in precision agriculture and smart farming[J]. Computers and Electronics in Agriculture, 2022, 198: 1-29.
- [5] LAURSEN M, JØRGENSEN R, MIDTIBY H, et al. Dicotyledon weed quantification algorithm for selective herbicide application in maize crops[J]. Sensors, 2016, 16(11): 1-28.
- [6] XU F, YAO X, ZHANG K, et al. Deep learning in cropland field identification: a review[J]. Computers and Electronics in Agriculture, 2024, 222: 1-24.
- [7] 高广帅,尚云琦,董燕.光学遥感图像小目标检测深度学习算法综述[J].中国图象图形学报,2025,30(11):3479-3505.
- [8] 余礼根,庄晏榕,邱枫,等.农业领域音频信息技术研究进展[J].农业机械学报,2025,56(10):223-248.
- [9] 何雪锋,周洁,陈德光,等.自然语言处理的深度学习模型综述[J].计算机应用与软件,2025,42(2):1-19.
- [10] 张琨,金坤,张方,等.火电厂煤场作业人员的多模态检测方法[J].天津理工大学学报,2020,36(6):35-41.
- [11] THAKUR A, VENU S, GURUSAMY M. An extensive review on agricultural robots with a focus on their perception systems[J]. Computers and Electronics in Agriculture, 2023, 212: 1-24.
- [12] MENSAH B, RAI N, BETITAME K, et al. Advances in weed identification using hyperspectral imaging: a comprehensive review of platform sensors and deep learning techniques[J]. Journal of Agriculture and Food Research, 2024, 18: 1-16.
- [13] 华嘉伟,李霞,段方涛,等.基于深度学习的激光除草机器人杂草识别定位方法研究[J].天津理工大学学报,2025,41(5):103-110.
- [14] BADGUJAR CM, POULOSE A, GAN H. Agricultural object detection with You Only Look Once (YOLO) algorithm: a bibliometric and systematic literature review[J]. Computers and Electronics in Agriculture, 2024, 223: 1-18.
- [15] SHAO Y, GUAN X, XUAN G, et al. GTCBS-YOLOv5s: a lightweight model for weed species identification in paddy fields[J]. Computers and Electronics in Agriculture, 2023, 215: 1-14.
- [16] SUN J, YOU J, LI F, et al. Research on improvement strategies for a lightweight

- multi-object weed detection network based on YOLOv5[J]. Crop Protection, 2024, 186: 1-19.
- [17] NIU W, LEI X, LI H, et al. YOLOv8-ECFS: a lightweight model for weed species detection in soybean fields[J]. Crop Protection, 2024, 184: 1-12.
- [18] FAN X, SUN T, CHAI X, et al. YOLO-WDNet: a lightweight and accurate model for weeds detection in cotton field[J]. Computers and Electronics in Agriculture, 2024, 225: 1-15.
- [19] DANG F, CHEN D, LU Y, et al. YOLOWeeds: a novel benchmark of YOLO object detectors for multi-class weed detection in cotton production systems[J]. Computers and Electronics in Agriculture, 2023, 205: 1-13.
- [20] LIU W, LU H, FU H, et al. Learning to upsample by learning to sample [C] // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). New York: IEEE, 2023: 6027–6037.
- [21] LI H, LI J, WEI H, et al. Slim-neck by GSConv: a lightweight-design for real-time detector architectures[J]. Journal of Real-Time Image Processing, 2024, 21(3): 1-11.

作者简介: 王兴伟 (2000—), 男, 硕士研究生, 研究方向: 深度学习、目标检测等。E-mail: 1561774080@qq.com

李霞 (通信作者) (1978—), 女, 教授, 博士, 研究方向: 智能农业机械等。E-mail: lixia0415@email.tjut.edu.cn