

全球小麦穗检测（GWHD）数据集：一个包含大量高分辨率RGB标注图像的多样化数据集，用于开发和评估小麦穗检测方法。

E. David ^{1,2†}, S. Madec ^{1,2†}, P. Sadeghi-Tehran ³, H. Aasen ⁴, B. Zheng ⁵, S. Liu ^{2,6}, N. Kirchgessner ⁴, G. Ishikawa ⁷, K. Nagasawa ⁸, M. A. Badhon ⁹, C. Pozniak ¹⁰, B. de Solan ¹, A. Hund ⁴, S.C. Chapman ^{5, 11}, F. Baret ^{2, 6}, I. Stavness ^{9*}, W. Guo ^{12*}

¹ Arvalis, 植物研究所, 约瑟夫与玛丽·哈金街3号, 75116 巴黎, 法国

² UMR1114 EMMAH, INRAE, 普罗旺斯-阿尔卑斯-蓝色海岸大区中心, 气候建筑, 圣保罗庄园, 机场路228号, CS 40509, 84914 阿维尼翁 CEDEX, 法国

³ 英国哈彭登罗斯汉姆斯特德研究所植物科学系

⁴ 苏黎世联邦理工学院农业科学研究所, Universitatstrasse 2, 8092 苏黎世, 瑞士

⁵ 澳大利亚联邦科学与工业研究组织农业与食品部, 昆士兰生物科学园区, 卡莫迪路306号, 圣卢西亚, 4067, QLD, 澳大利亚

⁶ 南京农业大学植物表型组学研究中心, 中国南京

⁷ 日本国家农业食品研究组织作物科学研究所

⁸ 日本国立农业食品研究组织北海道农业研究中心

⁹ 加拿大萨斯喀彻温大学计算机科学系

¹⁰ 加拿大萨斯喀彻温大学植物科学系

¹¹ 澳大利亚昆士兰大学食品与农业科学学院, 加顿4343, QLD, 澳大利亚

¹² 东京大学农学与生命科学研究生院, 日本东京都西东京市绿一丁目1-1-1

*通讯作者。邮箱: ian.stavness@usask.ca; guowei@g.ecc.u-tokyo.ac.jp

†这些作者对本研究的贡献均等

在植物图像中检测小麦穗是评估相关小麦性状的重要任务, 包括穗密度以及健康状况、大小、成熟度和芒的存在等穗特征。已有若干研究基于机器学习算法开发了从高分辨率RGB影像中检测小麦穗的方法。然而, 这些方法通常仅在有限数据集上进行了校准和验证。观测条件的高变异性、基因型差异、发育阶段及头部朝向等因素, 使得小麦穗检测成为计算机视觉领域的挑战。此外, 由于运动或风力导致的可能模糊, 以及密集群体中穗部的重叠, 使这项任务更加复杂。通过国际联合协作, 我们构建了一个大规模、多样化且标注完善的麦穗图像数据集, 称为全球麦穗检测（GWHD）数据集。该数据集包含4,700张高分辨率RGB图像和190,000个标注麦穗, 这些样本来自全球多个国家, 涵盖不同生长阶段及多种基因型。在开发新的麦穗检测数据集时, 我们提出了图像采集指南、遵循FAIR原则的最小元数据关联规范以及统一的穗部标注方法。GWHD数据集已公开发布于<http://www.global-wheat.com/>, 旨在推动麦穗检测方法的开发与基准测试。

关键词: 数据集, 小麦穗/穗轴/穗, 检测, 深度学习, RGB

1. 介绍

小麦与水稻、玉米并列为全球种植最广泛的谷物作物。20世纪50年代，诺曼·博劳格培育出半矮秆小麦品种并配套开发农艺学体系（即“双绿革命”），为新兴国家的粮食安全作出关键贡献，成功使3亿人免于饥荒[1]。然而经过数十年的快速增长后，自20世纪90年代初以来小麦产量增速已明显放缓[2][3]。传统育种仍高度依赖人工观察，而基因组选择、新型高通量表型分析技术或两者的结合[4]-[7]，可能成为提升遗传增益的重要突破。这些技术对筛选与产量潜力、抗病性或非生物胁迫适应性相关的关键性状至关重要。尽管高通量表型数据采集已成现实，但如何建立高效稳健的模型从原始数据中提取性状特征，仍是亟待攻克的技术难题。在所有性状中，小麦穗密度（单位地面面积上的小麦穗数）是主要的产量构成要素，目前育种试验中仍采用人工评估，这种方式劳动密集且会导致约10%的测量误差[8][9]。因此，亟需开发基于图像的方法来提高田间小麦穗计数的通量和准确性，以帮助育种者在育种选择中平衡产量构成要素（植株数量、穗密度、单穗粒数、单粒重量）之间的关系。

随着GPU性能的提升和大规模数据集的涌现[10][11]，深度学习已成为包括目标检测[12]、实例分割[13]、语义分割[14]和图像回归[15][16]在内的众多计算机视觉任务的前沿技术。近期，多位学者提出了专为基于图像的植物表型分析设计的深度学习新方法[17]-[19]。针对小麦穗的定量分析，已有多种方法从RGB高分辨率图像中提取数据。在[8][9]的研究中，研究者通过Faster-RCNN目标检测网络验证了其小麦穗检测的可行性。文献[8]估算表明，当图像分辨率受控时，此类方法的相对计数误差约为10%。文献[20]中，研究者开发了一种用于小麦穗语义分割的编码器-解码器卷积神经网络（CNN）模型，其性能优于传统手工设计的计算机视觉技术。文献[21]则开发了小麦穗检测与概率跟踪模型，用于表征田间生长小麦植株的运动特征。

尽管先前研究已在单个数据集上测试了小麦穗检测方法，但这些深度学习模型在实际应用中难以扩展到真实表型分析平台，因其训练数据集有限，导致在新场景下外推时存在预期困难[8][22][23]。多数训练数据集在基因型、地理区域和观测条件方面存在局限性。小麦穗形态可能因基因型差异而显著不同，包括穗部形态（如大小、倾斜度、颜色及是否带芒）的显著变化。从出苗到成熟期间，由于成熟与衰老过程，穗部外观及背景冠层也会发生显著改变[24]。此外，种植密度和模式在全球范围内因不同种植系统和环境而异，且在种植密度较高的田地中，小麦穗常相互重叠并遮蔽。

处理有限数据集的常见策略是：在表型试验田块的部分区域训练卷积神经网络（CNN）模型，再用剩余区域进行测试[25]。这种做法存在根本性缺陷——实证方法在构建因果模型时缺乏理论保障，无法确保CNN模型对新采集数据具有鲁棒性。此外，不同研究者方法的对比需要海量数据支持。但当前这类大规模、多样化表型计数数据集并不存在，因为它们主要由单一机构独立采集，导致用于训练和测试模型的基因型数量、环境条件及观测数据均存在局限。更棘手的是，由于标注过程繁琐费时，实际处理的图像仅占采集总量的极小部分。最后，不同机构的标注规范可能存在差异，这将影响模型在共享标注数据集上的训练效果。

为满足对大规模、多样化且标注统一的小麦穗数据集的需求，我们开发了全球小麦穗检测（GWHD）数据集，该数据集可用于评估计算机视觉领域提出的各类方法。GWHD数据集整合了来自七大洲九个不同机构的多个数据集。本文详细阐述了数据收集过程、图像特征与标注的统一标准，以及小麦穗检测挑战赛的组织架构。最后，我们探讨了数据集生成过程中遇到的问题，并为希望贡献标注图像以扩充GWHD数据集的未来贡献者提供了指导建议。

2. 数据集构成

2.1. 实验

GWHD数据集中的标注图像来源于2016至2019年间由九家机构在十个不同地点（表1）采集的数据集，涵盖欧洲、北美、澳大利亚和亚洲的基因型。这些独立数据集被称为“子数据集”，其采集实验采用不同种植方式，行距从12.5厘米（ETHZ_1）到30.5厘米（USask_1）不等。实验特征详见表1，包括低播种密度（UQ_1、UTokyo_1、UTokyo_2）、正常播种密度（Arvalis_1、Arvalis_2、Arvalis_3、INRAE_1、NAU_1部分）和高播种密度（RRes_1、ETHZ_1、NAU_1部分）。GWHD数据集涵盖多种土壤气候条件，包括高产环境（如法国皮卡第地区的壤土，Arvalis_3）、山地环境（如瑞士高原的粉砂黏土，ETHZ_1）或上普罗旺斯阿尔卑斯地区（Arvalis_1、Arvalis_2）。在Arvalis_1、Arvalis_2、UQ_1、NAU_1等实验中，设计用于比较灌溉与水分胁迫环境。

子数据集名字	机构	1940年前拉脱维亚国家	的货币单位(°)	年	数日期	靶向阶段	行间隔厘米	播种密度(种子·平方米)	数基因型	
UTokyo_1	NARO & 东京大学	日本	36.0N	140.0E	2018	3	花后	15	186	66
UTokyo_2	NARO & 东京大学	日本	42.8N	143.0	2016	6	开花*	12.5	200	1
Arvalis_1	阿瓦利斯	法国	43.7N	5.8E	2017	3	花后 - 成熟	17.5	300	20
Arvalis_2	阿瓦利斯	法国	43.7N	5.8E	2019	1	花后	17.5	300	20
Arvalis_3	阿瓦利斯	法国	49.7N	3.0E	2019	3	花后 - 成熟	17.5	300	4
INRAE_1	INRAE	法国	43.5N	1.5E	2019	1	花后	16	300	7
USask_1	大学 萨斯喀彻温省	加拿大	52.1N	106.W	2019	1	n.a	30.5	250	16
RRes_1	罗瑟姆斯特德 研究	英国	51.8N	0.36W	2016	1	n.a	n.a	350	6
ETHZ_1	ETHZ	瑞士	47.4N	8.6E	2018	1	n.a	12.5	400	354
NAU_1	南京农科大学	中国	31.6N	119.4E	2018	1	开花*	20	300或450	5
UQ_1	昆士兰大学	澳大利亚	27.5S	152.3E	2016	1	开花 成熟	22	150	8

表1： GWHD 数据集图像采集实验的特征

* 对图像进行了仔细检查，以确保花头已完全发育并开花。

2.2. 图像采集

GWHD 数据集包含通过多种地面表型分析平台和相机采集的RGB图像（表2）。图像采集高度介于地面以上1.8米至3米之间。相机焦距范围为10至50毫米，传感器尺寸各异。由于相机配置差异，地面采样距离（GSD）范围为0.10至0.62毫米，沿图像对角线的半视野范围为10°至46°。假设小麦穗直径为1.5厘米，所获取的几何形状数据（GSDs）分辨率足以通过肉眼观察识别穗部结构及芒叶。虽然所有图像均采用正视方向采集，但由于不同相机镜头特性差异，部分子数据集可能存在几何畸变现象，其中 UTokyo_1 和 ETHZ_1 数据集受此影响尤为显著。各机构采用的手持式、推车式、小型移动设备及龙门式系统等不同采集平台，导致相机传感器与采集配置存在多样性，这种差异性将有助于训练深度学习模型，使其在不同图像采集条件下具备更强的泛化能力。

子数据集名称	向量	照相机	焦距毫米	场视度(°)*	射击方式	图像大小(像素)	距离至地面(米)	GSD (mm/px)
UTokyo_1	马车	佳能Shot G9 X Mark II	10	38.15	自动的	5472×3648	1.8	0.43
UTokyo_2	手持的	奥林巴斯 μ 850 和索尼DSC-HX90V	7/4	45.5	自动的	3264×2488 & 4608×3456	1.7	0.6
Arvalis_1	手持的	索尼Alpha ILCE - 6000	50 & 60	7.1	自动的	6000×4000	2.9	0.10-0.16
Arvalis_2	手持的	索尼 RX0	7.7	9.99	自动的	800x800 [†]	1.8	0.56
Arvalis_3	手持的	索尼 RX0	7.7	9.99	自动的	800x800 [†]	1.8	0.56
INRAE_1	手持的	索尼 RX0	7.7	9.99	自动的	800×800 [†]	1.8	0.56
USask_1	微型的车辆	FLIR Chameleon3 USB3	16	19.8	固定的	2448×2048	2	0.45
RRes_1	构台	普瑞西拉 GT 3300 联合视觉	50	12.8	自动的	3296×2472	3-3.5 [§]	0.33-0.385
ETHZ_1	构台	佳能EOS 5D 第二版	35	32.2	固定的	5616×3744	3	0.55
NAU_1	手持的	索尼 RX0	24	16.9	自动的	4800×3200	2	0.21
UQ_1	手持的	佳能550D	55	17.3	自动的	5184×3456	2	0.2

表2：构成 GWHD 数据集的子数据集图像特征。所有摄像头均朝垂直下方拍摄。

* 视野以对角线方式测量。报告的测量值为半角。

[†]原始图像经裁剪后，从中部区域提取出尺寸为800x800的子图像

[§]相机垂直于地面放置，并自动调整以确保两者之间保持2.2米的距离
摄像头与遮阳篷。

2.3. 数据协调

组装 GWHD 数据集的一个重要方面是协调各子数据集（图1）。首先对图像进行人工检查以确保其可被准确解读。当头部无法清晰可见时，移除生长阶段过早获取的图像（图2d）。由于茎秆在此阶段开始弯曲时头部容易重叠，因此大多数图像的采集时间也早于头部衰老现象的出现。

物体尺度（即物体在像素中的大小）是物体检测方法设计中的重要因素。
[8]物体尺寸取决于物体大小（毫米）和图像分辨率。小麦穗的尺寸可能因基因型和生长条件不同而有所差异，但通常直径约1.5厘米，长度约10厘米。实际图像分辨率在小麦穗层面存在显著差异：GSD 相差5倍（表1），而穗级分辨率还受冠层高度和相机全景效应影响。当图像采集距离冠层过近时，全景效应会显著增强。因此对图像进行重新缩放，以保持穗级分辨率的相似性。采用双线性插值法对原始图像进行上采样或下采样处理。各子数据集所应用的缩放因子如表3所示。

大多数深度学习算法采用方形图像块进行训练。当原始图像被裁剪为方形块时，块的尺寸经过精心选择，以降低头部结构跨越块边缘导致部分被截断的概率。因此，图像被分割成1024×1024的方形块，每个块包含约20至60个头部结构，仅有少数头部结构会跨越块边缘。根据子数据集的不同，原始图像对应的方形块数量在1到6个之间变化（表3）。在本文后续讨论中，这些方形块将统称为“图像”。




图1：所进行的图像配准流程概述。首先采用双线性插值上采样或下采样技术对图像进行重缩放处理，随后将重缩放后的图像分割为 1024×1024 像素的正方形块。

2.4. 贴标

我们开发了一个基于网络的标注平台，用于处理共享子数据集的评估与标注工作，该平台采用COCO标注器（<https://github.com/jsbroks/coco-annotator>; [26]）实现。平台集成了所有标注对象所需的工具，并支持多用户同时访问，从而实现跨机构协同标注。小麦穗头的标注通过绘制包含穗头所有像素的边界框进行交互式标注。若穗头被叶片或其他穗头遮挡导致不可见，则标注难度显著增加。我们仅对至少可见一个小穗的局部遮挡穗头进行标注，这种情况多见于早期阶段获取的图像，此时穗头尚未完全显现。当使用广角相机（如 UTokyo_2 或 ETHZ_1）拍摄时，穗头间的重叠现象更为常见。这些重叠现象主要出现在图像边缘且视角较为倾斜的情况下。当边界框过大而无法包含伞骨时，仅限于头部区域（图2a）。此外，仅当头部基底部分可见超过30%时，才会对图像边缘裁剪后的头部进行标注（图2e）。




图2：小麦穗难以标注的示例。这些示例为数据集中图像的放大视图，包含不同缩放比例。示例包括重叠穗（a-c）、萌发期穗(d)、图像边缘部分被截断的穗(e)以及低光照条件下的图像(f)。需注意的是，图像(d)因萌发期穗的模糊性已被移出数据集。图像(e)中的小麦穗未被标注，因其基部可见部分不足30%，具体定义见2.4节。

已有若干机构对其子数据集进行了标注。对于未标注的数据集，我们采用了一种“弱监督深度学习框架” [27]，以高效完成这些子数据集的图像标注。所使用的模型为YoloV3。

[28] 该模型在 UTokyo_1 和 Arvalis_1 子数据集上进行训练，随后应用于未标注子数据集。保留置信度评分 ≥ 0.5 的框，并向用户提出修正建议。与完全手动标注相比，这种半自动主动学习使标注效率提升了四倍。具体流程详见图S1。

该首次标注结果随后由两名独立于子数据集机构的人员进行复核。当观察到评审者之间存在较大差异时，将启动新一轮标注与复核流程。约20名人员参与了此次标注工作。这种协作流程与重复复核确保了子数据集间具有高度准确性与一致性。

3. 数据集描述

3.1. 一般统计

GWHD 数据集包含从11个子数据集中获取的2219张原始高分辨率RGB图像中提取的4,698个正方形区域（表3）。该数据集包含188,445个标注头部，平均每张图像40个头部，与每张图像20至60个目标头部的预期值高度吻合。但各子数据集间及内部的头部分布范围较广（图3a）。我们额外纳入约100张无头部图像以模拟实际拍摄环境，同时增加基准测试难度。少数图像头部数量超过100个，最多达到120个。由于基因型和环境条件的影响，头部密度存在差异，因此在多个子数据集中可观察到多个对应峰值（图3b）。头部周围边界框的尺寸呈现轻微偏斜的高斯分布，典型中位尺寸为77像素（图3b）。该典型尺寸通过面积的平方根计算得出，与目标尺度（约1.5厘米 $\times$ 10厘米的头部尺寸）高度吻合，平均分辨率接近0.4毫米/像素，相当于每个头部的典型尺寸为97像素。尽管简单的水平投影面积与RGB相机的观测几何结构并不完全对应，但子数据集间物体尺度的协调性可通过图4进一步直观验证。

子数据集名字	数获得的图像	数每片图像	最初的GSD毫米	抽样因子	已用GSD毫米	数贴上标签图像	数贴上标签正面朝上的	平均数头数图像
UTokyo_1	994	1	0.43	1	0.43	994	29174	29
UTokyo_2	30	4	0.6	2	0.3	120	3263	27
Arvalis_1	239	6	0.23	0.5	0.46	1055*	45716	43
Arvalis_2	51	4	0.56	2	0.28	204	4179	20
Arvalis_3	152	4	0.56	2	0.28	608	16665	27
INRAE_1	44	4	0.56	2	0.28	176	3701	21
USask_1	100	2	0.45	1	0.45	200	5737	29
RRes_1	72	6	0.33	1	0.33	432	20236	47
ETHZ_1	375	2	0.55	1	0.55	747*	51489	69
NAU 1型	20	1	0.21	1	0.21	20	1250	63
UQ_1	142	1	0.2	0.5	0.4	142	7035	50
总数	2219	-	-	-	-	4698	188445	-

表3：全球小麦穗检测各组成部分的统计学数据
 *部分标记图像在标注过程中已被移除




图3： GWHD 数据集中每张图像的边界框数量分布(a)和边界框尺寸分布(b)。
 *边界框尺寸定义为边界框面积（以像素为单位）的平方根。

3.2. 采样基因型、环境及发育阶段的多样性

GWHD 数据集所采样的获取条件多样性在图4中得到充分展示：光照条件变化多样，头部与背景的外观呈现广泛差异。此外，我们还观察到头部朝向和观察角度的多样性，从近乎正下方的角度到主要呈倾斜角度，如 ETHZ_1 所示（图4）。从多个子数据集中提取的边界框样本（图5）显示，边界框面积和纵横比会随头部朝向及观察方向的不同而变化。观察到头部外观存在显著多样性，包括顶叶的有无、大小、头部颜色及模糊程度的差异。此外，当边界框跨越图像边缘时，部分头部会被截断。




图4: 不同采集部位图像裁剪与缩放后的示例。




图5: 各子数据集的边界框选择示例。所有显示的边界框均采用相同像素尺寸。

3.3. 与其他数据集的比较

植物表型研究领域已提出多个开源数据集。CVPPP 数据集[29]被广泛应用于莲座叶计数和实例分割。小松菜数据集同样包含莲座叶分割结果，但数据来源于延时视频[30]。诺丁汉ACID小麦数据集收录了在受控环境中拍摄的小麦穗图像，并标注了单个小穗。

[31]然而，目前公开的开源数据集中包含户外田间环境图像的资源相对匮乏，而这类图像对于作物育种和农业实践中的表型分析至关重要。已有少量数据集被用于杂草分类研究[32][33]。GrassClover数据集收录了牧草田的图像及草类、三叶草类和杂草植被类型的语义分割标注[34]。关于高粱计数的数据集

[27] [35]和小麦穗[36]也已发表，并附有点状注释。

在面向对象检测的表型数据集方面，我们的 GWHD 数据集目前是目前公开可获取的最大规模的开放标签数据集，专门用于田间植物表型分析。MinneApple[37]是唯一

在表型领域，该数据集在多样性方面具有可比性，但在图像数量和位置多样性方面有所不足。其他数据集如MS COCO[38]或Open Images V4[39]规模更大，涵盖更多物体类型，适用于广泛的应用场景。这些数据集对应的图像通常包含较少物体，每张图像通常少于十个（图6）。然而，某些特定数据集如 PUCPR [40]、CARPK [41]、SKU-110K[42]专为检测密集场景中的物体（如汽车、产品）而设计。它们的物体密度远高于 GWHD 数据集，但 PUCPR 和 CARPK 的图像数量较少，而 SKU-110的数据集图像数量则多于我们的 GWHD 数据集（图6）。GWHD 数据集特有的高重叠和遮挡物体出现频率，使得标注和检测更具挑战性，尤其是与几乎不存在遮挡的SKU-110K相比。最后，小麦穗是具有广泛外观变异性的复杂对象，如先前研究所示，其周围环境背景极为多样，这将构成比检测汽车或商店货架上密集排列的产品更为困难的问题。




图6：GWHD 数据集与其他目标检测数据集的对比。两个坐标轴均采用对数刻度。

4. 目标应用场景：小麦穗检测挑战

该数据集的主要目标是为解决从RGB高分辨率图像中检测小麦穗的挑战性问题做出贡献。2020年5月至8月将举办一场开放的机器学习竞赛，使用 GWHD 数据集进行小麦穗检测方法的训练和测试，以进行基准测试（<http://www.global-wheat.com/2020-challenge/>）。

4.1. 训练集与测试集分割

在机器学习研究中，通常会将数据集随机划分为训练集和测试集。然而，针对 GWHD 竞赛，我们特别旨在测试该方法在未见过的基因型、环境及观测条件下的表现。因此，我们将欧洲和北美的所有图像归为训练数据集，该数据集涵盖足够多样的图像以训练通用的小麦穗检测模型。该训练数据集包含3422张图像，占整个 GWHD 数据集的73%。测试数据集包含来自澳大利亚、日本和中国的全部图像，共计1276张，用于评估模型性能，包括对没见过图像的鲁棒性。

4.2. 评估指标

在 GWHD 数据集中，选择边界框作为标签使其适用于目标检测任务。通常采用真阳性与假阳性计算的平均精度来量化目标检测任务的性能。真阳性指预测边界框与最近标注边界框的交并比（IoU）大于或等于0.5的情况，假阳性则指预测边界框与最近标注边界框的交并比严格小于0.5的情况。当两个预测边界框的交并比均大于或等于0.5时，以置信度更高的边界框作为真阳性，另一个则作为假阳性。用于评估定位性能的指标是记为mAP@0.5的平均精度。检测单个麦穗有助于表征其大小、倾斜度、颜色或健康状况，但每张图像中麦穗的数量同样是极具价值的特征参数。未来使用 GWHD 数据集的竞赛可聚焦于小麦穗数统计，采用均方根误差（RMSE）、相对均方根误差（rRMSE）和决定系数（R2）等指标来量化目标计数方法的性能。

4.3. 基线法

为设定 GWHD 数据集的基准检测精度，我们基于标准目标检测方法提供结果。我们训练了一个两阶段检测器Faster- RCNN [12]，其骨干网络采用ResNet34和ResNet50。Faster- RCNN 是最受欢迎的目标检测模型之一，曾被Madec等人[8]采用。选择ResNet34与ResNet50组合是因为前者不易过拟合且训练速度更快。由于内存限制，输入尺寸设定为512×512像素。我们从训练数据集中每张图像随机抽取10个512×512像素的补丁，最终形成包含34220个补丁的训练集。通过从1024×1024像素的测试图像中定期提取512×512像素的重叠补丁进行预测，随后合并结果。经过10个周期（总计342200次迭代）后，两种骨干网络在第3周期均获得最佳模型。该模型的mAP@0.5值为0.77，每张图像平均 RMSE 为12.63个麦穗，对应rRMSE=39%。回归系数为0.57。所有结果详见图S2。标准目标检测网络在 GWHD 数据集上的表现相对欠佳，这为未来采用新方法实现显著改进提供了契机。GWHD 竞赛预计将催生新的麦穗检测方法，从而获得更精确的结果。

5. 讨论

5.1. 图像采集建议

要准确识别小麦穗，需确保穗部完全萌发且在图像中清晰可见，同时尽量减少穗部与叶片的重叠。针对特定基因型和环境条件，我们发现小麦茎秆在后期灌浆阶段容易弯曲，导致穗部重叠现象加剧。反之，在抽穗至开花阶段，部分穗部尚未完全萌发，因而难以辨识。因此建议在开花后立即拍摄图像，此时小麦穗已完全萌发且仍保持直立状态。

在图像采集时，建议采用接近地平线的观测方向以减少头部重叠，尤其适用于头部密度较高的群体。同样，窄视场角也是优选方案。但若相机高度接近树冠顶部，窄视场角可能导致图像覆盖范围过小。因此我们建议增加相机高度以扩大采样区域，减少图像边缘被裁剪的头部数量。当使用头部识别技术估算种群密度时，采样区域的大小至关重要。最小采样区域应采用我们的方形补丁，即1024×1024像素（0.4毫米/像素），对应约40 cm²的面积。为实现该采样区域且保持±15°的窄视场角，相机与树冠顶部的距离应约为1.0米。不过在种群密度估算中，建议采用更大的采样区域，至少需采样100 cm²以考虑行间可能存在的异质性。这可通过2.相机与树冠顶部的距离为5米。

在估算小麦穗密度（即单位种植面积上的穗数）时，准确掌握采样区域的尺寸至关重要。由于图像采集采用非平行几何结构，且存在显著的“鱼眼”镜头畸变效应，这会导致采样区域的不确定性。即使在我们典型案例中畸变效应有限（视场角±15°），当图像采集距离植株冠层顶部2.5米时，若对冠层高度估算存在10厘米误差，将导致采样区域误差达8%，这种误差会直接反映在穗密度测量结果中。此外，如何确定计算采样区域的参考高度仍是一个开放性问题，因为在小麦植株群体中，不同植株的穗部高度差异可能超过25%。

cm，这导致采样区域在最低与最高头部之间存在21%的差异。后续研究应进一步探讨这一重要问题。

最终，我们的经验表明，要实现高效的麦穗检测，需要在冠层顶部使用亚毫米级分辨率。然而，最佳分辨率尚未确定。先前研究[8]推荐0.3毫米 GSD，而 GWHD 数据集包含的 GSD 范围为0.28至0.55毫米。后续研究应深入探讨小麦成像的这一关键问题，特别是利用无人机观测数据在大型小麦育种实验中进行麦穗密度估算的可能性。

5.2. 与子数据集及FAIR原则相关的最低限度信息

FAIR原则（可发现性、可访问性、可互操作性和可重用性[43]）应适用于 GWHD 数据集中的图像。如文献[44]所述，每张图像应关联一组最小元数据集以验证FAIR原则。元数据缺失问题影响了数据的精确统一，成为进一步数据解读[45]及潜在荟萃分析的限制因素。因此，我们建议为每张图像和子数据集附加最小限度的信息。在我们的案例中，子数据集通常对应一个图像采集会话，即同一日期、使用同一相机进行的实验中获取的一系列图像。实验元数据包含与该会话农艺特征相关的所有信息；采集元数据则涵盖与所用相机及采集设备相关的所有信息。这两类数据均可在会话层面和图像层面进行定义。我们的建议总结于表4。我们建议尽可能附加更多元数据（如相机参数设置：型号、白平衡校正等），因为这能为后续数据复用提供背景信息。

	会话级别	图像水平
实验元数据	实验名称（PUID）† 机构名称 GPS坐标（°） 联系人电子邮箱 会议日期（年月日） 小麦品种（硬质小麦、软质小麦...） 发育阶段/成熟阶段*	Microplot id 行间距 播种密度 基因型名称（或任何标识符）† 是否存在羽毛。
采集元数据	载体特性： 名称 类型（手持式、推车式、Phenomobile、龙门式、无人机）采样程序 距地面高度（米）* 相机特性 型号，镜头焦距（毫米），传感器矩阵像素尺寸（μm）传感器尺寸（像素×像素）	相机光圈快门速度ISO 相机至树冠距离（米）‡ 微图中图像位置§

表4：小麦穗图像应关联的最小元数据。

* 若该标识符在单次会话中具有变异性（†持久唯一标识符， PUID），则可在图像层级进行替代报告。该标识符可采用DOI格式，例如受《植物遗传资源保护条例》监管的遗传资源。

粮食和农业（<https://ssl.fao.org/glis>）或任何其他标识符，包括遗传物质维护者的信息

材料，成熟阶段‡ 相机与树冠之间的距离是协调数据集并计算密度的
关键信息

在采集过程中应予以密切监测。

§若同一显微图谱存在多幅图像。

5.3. GWHD 扩张需求

GWHD 数据集的创新性和独特性在于其汇聚了来自全球各地的大量贡献者，从而形成了图像的广泛多样性。然而，当前数据集未能充分覆盖各大陆及环境条件的多样性： GWHD 数据集中超过68%的图像来自欧洲，43%来自法国。此外，非洲、拉丁美洲和中东等地区目前仍存在数据缺失。作为未来工作，我们希望扩展 GWHD 数据集以获得更全面的数据集。因此，我们邀请潜在贡献者通过提交子数据集来补充 GWHD 数据集。为保持高度一致性并遵循FAIR原则，需遵循图像采集指南及相关元数据规范。我们鼓励潜在贡献者通过www.global-wheat.com联系通讯作者。未来我们还计划扩展 GWHD 数据集，用于小麦穗的分类和分割任务。

例如，需更新小麦穗的大小或开花状态等指标。这一扩展将需要对现有标签进行更新。

6. 结论

用于定位和识别图像中小麦穗的物体检测方法，有助于估算小麦群体的穗密度。穗检测也可被视为寻找其他小麦性状的第一步，包括行间空间分布、芒的存在、大小、倾斜度、颜色、灌浆期及健康状况。这些性状可能对小麦育种者具有实用价值，部分性状还能帮助农民更好地管理作物。

为提升小麦穗检测与定位的精度和可靠性，我们构建了全球小麦穗检测数据集——一个包含海量多样化小麦穗图像的综合数据集。该数据集旨在开发并评估业界提出的穗检测方法，体现了国际学术界的广泛协作成果。通过整合多样化子数据集，我们取得的重要成果包括：制定图像采集规范、遵循FAIR原则的最小元数据标准，以及小麦穗标记工具。我们期待这些规范能帮助从业者在未来通过更多子数据集扩展 GWHD 数据集，从而呈现更丰富的基因型与环境多样性。该 GWHD 数据集已联合开放研究竞赛共同发布，旨在为全球各地小麦种植区的穗检测提供更精准可靠的方法。竞赛中提出的解决方案将作为开源代码向植物表型研究领域公开共享。

致谢

法国团队获得了 ANRT CIFRE 资助项目 EtienneDavid 的支持，该项目由 Arvalis 共同资助。本研究部分由 ANR phenome、ANR breedwheat、CASDAR literal 和 FSOV “Plastix” 等项目资助。衷心感谢参与法国数据集注释的各位，包括 Frederic Venault、Xiuliang Jin、Mario Serouard、Ilias Sarbout、Carole Gigot、Eloise Issert 和 Elise Lepage。

日本团队获得了 JST 克雷斯特基金（资助编号 JPMJCR16O3、JPMJCR16O2、JPMJCR1512）和日本 MAFF 创新农业智能育种系统（BAC1003）的支持。衷心感谢参与日本数据集注释的各位，包括和田小津、石井正典、神崎龙一、石桥沙代子、金子澄子。

加拿大团队获得加拿大第一研究卓越基金（Canada First Research Excellence Fund）通过植物表型与成像研究中心（Plant Phenotyping and Imaging Research Center）提供的资助。特别感谢 Steve Shirliffe、Scott Noble、Tyrone Keep、Keith Halco 及 Craig Gavelin 对野外站点的管理及图像采集工作。

罗瑟姆斯特德研究所获得了英国生物技术与生物科学研究委员会（BBSRC）作为‘设计未来小麦’项目（BB/P016855/1）的一部分资助。我们还要感谢领导 DFW 项目的马尔科姆·J·霍克斯福德教授，以及在罗瑟姆斯特德研究所开展实验的尼古拉斯·维尔莱特博士。

澳大利亚加顿数据集来源于 CSIRO 与 UQ 联合开展的田间试验，该试验的实施与测量部分由 GRDC 谷物研究与发展公司（GRDC）通过项目 CSP00179 资助。一项新的 GRDC 项目涉及多位作者，并支持他们对本文的贡献。

本研究在中国收集的数据集由南京农业大学高层次人才引进计划（项目编号：440—804005）资助。衷心感谢周杰及多位志愿者的贡献。
南京农业大学完成注释。

ETHZ 的数据集收集工作得到了作物科学组负责人 Achim Walter 教授的支持。特别感谢 Kevin Keller 对 ETHZ 数据集的初步准备，以及 Lara Wyser、Ramon Winterberg、Damian Kach、Marius Hodel 和 Mario Serouard（INRAE）对 ETHZ 数据集的标注工作，同时感谢 Brigita Herzog 和 Hansueli Zellweger 在作物管理方面的支持。

作者贡献：

E.D.、S.M.、B.S. 和 F.B. 负责法国数据集的野外实验与数据收集工作。P.S.T. 负责英国数据集的野外实验与数据收集工作。H.A.、N.K. 和 A.H. 负责野外实验与数据收集工作。

瑞士数据集的收集工作由G. I.、K.N.和W.G.负责组织现场实验与数据采集。日本数据集的现场实验与数据采集由S.L.和F.B.负责组织。中国数据集的现场实验与数据采集由C.P.、M.B.和I.S.负责组织。

加拿大数据集的现场实验与数据收集由B.Z.和S.C.C.负责组织。澳大利亚数据集的现场实验与数据收集由E.D.和S.M.负责组织。W.G.、E.D.和S.M.负责子数据集的协调工作。


构建了初始小麦穗检测模型并完成预标记流程。E.D.负责标记平台的搭建，所有作者均参与数据标记与质量检查工作。E.D.构建了竞赛基准模型。E.D.与S.M.共同撰写了论文初稿，两人对本研究贡献相当。所有作者均对最终版本提出修改意见并予以批准。

资助：纳入致谢部分。

竞争利益声明：作者声明就本文发表不存在利益冲突。


数据可用性：GWHD 数据集将在线公开（www.globalwheat.com）根据MIT许可协议。

补充材料



图S1：所提出的“弱监督深度学习框架”用于高效预标注图像。

- (a) 原始图像输入。
- (b) 对随机选取的原始图像进行标注工作。
- (c) 使用(b)中的标注图像训练初始模型。
- (d) 将初始模型应用于左侧原始图像。
- (e) 将生成的标签和图像输入图像标注应用程序，由人工标注者验证边界框位置及修正。
- (f) 将修正后的标签及图像添加至数据池(b)
- (g) 在完成(a)-(f)-(d)步骤的迭代后，通过每次迭代结束时对训练模型的评估确定达到预期性能，最终获取标注完成的数据集。



图S2: Faster- RCNN 基线模型在ResNet34和ResNet50上的分轮次结果(RMSE、rRMSE、R²、[mAP@0.5](#))。两种骨干网络在第3轮次均获得最佳模型。

参考文献

- [1] M. P. 雷诺兹与N. E. 博劳格,《创新技术与新技术在国际协作小麦改良中的应用》,《农业科学杂志》,第144卷第2期。剑桥大学出版社,第95–110页,2006年4月。
- [2] N. Brisson、P. Gate、D. Gouache、G. Charmet、F. X. Oury与F. Huard合著的《欧洲小麦产量停滞原因:法国综合数据分析》,载于《作物研究》2010年10月刊第119卷第1期,第201–212页。
- [3] B. Schauburger、T. Ben-Ari、D. Makowski、T. Kato、H. Kato 和 P. Ciais 合著的《法国主要作物产量趋势、变异性与停滞分析(跨越一个多世纪)》,发表于《科学报告》2018年12月第8卷第1期,第1–12页。
- [4] M. Reynolds 等,《育种友好型表型分析》,《植物科学》。爱思唯尔爱尔兰有限公司,第110396页,2020年1月。
- [5] J. Crain、S. Mondal、J. Rutkoski、R. P. Singh 和 J. 波兰,《结合高通量表型分析与基因组信息以提高小麦育种预测与选择准确性》,《植物基因组》第11卷第1期,第1–14页,2018年3月。
- [6] A. Hund, L. Kronenberg, J. Anderegg, K. Yu, A. W.-A. 在作物育种中的应用,以及 U. 2019,《谷物生长发育特征的非侵入性表型分析》。剑桥,2019年。
- [7] A. Walter、F. Liebisch 和 A. Hund,《植物表型分析:从豆类称重到图像分析》,《植物方法》第11卷第1期,第14页,2015年3月。
- [8] S. Madec、X. Jin、H. Lu、B. De Solan、S. Liu、F. Duyme、E. Heritier与F. Baret合著的《基于深度学习技术的高分辨率RGB影像中耳密度估算》,发表于《农业、林业与气象学》2019年1月刊第264卷第225–234页。
- [9] M.M Hasan、J.P. Chopin、H. Laga与S.J Miklavcic,《基于卷积神经网络的小麦穗检测与分析》,《植物方法》第14卷第1期,第100页,2018年
- [10] M.Z. Alom、T.M. Taha、C. Yakopcic、S. Westberg、P. Sidike、M.S. Nasrin、M. Hasan、B. C. Van Essen、A. Awwal 与 V.K. Asari 合著的《深度学习理论与架构的前沿综述》,载于《电子学报》2019年第8卷第3期。
- [11] O. 鲁萨科夫斯基、J. 丁、H. 苏、J. 克劳斯、S. 萨提什、S. 马、Z. 黄、A. 卡帕西、A. 科斯拉、M. 贝尔斯坦、A. C. 伯格和L. 费飞飞,《ImageNet大规模视觉识别挑战》,《国际计算机视觉杂志》,第115卷第3期,第211–252页,2015年。
- [12] S. Ren、K. He、R. Girshick 和 J. Sun,《更快的 R-CNN: 基于区域提议网络的实时目标检测》,IEEE 图形分析与机器智能汇刊,第39卷第6期,第1137–1149页,2017年6月。
- [13] K. He、G. Gkioxari、P. Dollar 和 R. Girshick,《Mask R-CNN》,《IEEE模式分析与机器智能汇刊》,第42卷第2期,第386–397页,2020年2月。
- [14] O. Ronneberger、P. Fischer与T. Brox合著的《U-net: 用于生物医学图像分割的卷积网络》一文,收录于2015年出版的《计算机科学讲义》(含《人工智能讲义》及《生物信息学讲义》系列),该书第9351卷第234–241页。
- [15] S. Aich 与 I. Stavness,《全局求和池化: 一种适用于大型图像小数据集对象计数的泛化技巧》。

- [16] 熊浩、卢浩、刘晨、刘亮、曹哲和沈晨,《从开放集到闭集:通过空间分割与征服法计数对象》,2019年8月。
- [17] M. P. Pound、J. A. Atkinson、D. M. Wells、T. P. Pridmore 和 A. P. French,《多任务植物表型分析的深度学习》,bioRxiv,第204552页,2017年10月。
- [18] J. R. Ubbens 与 I. Stavness,《深度植物表型组学:一种用于复杂植物表型分析任务的深度学习平台》,《植物科学前沿》,第8卷,第1190页,2017年7月。
- [19] A. K. Singh、B. Ganapathysubramanian、S. Sarkar 和 A. Singh,《植物胁迫表型分析的深度学习:趋势与未来展望》,《植物科学趋势》第xx卷,第1-16页,2018年。
- [20] P. Sadeghi-德黑兰、N. Virlet、E. M. Ampe、P. Reyns与M. J. Hawkesford合著的《DeepCount:基于简单线性迭代聚类与深度卷积神经网络的小麦穗自动化方法》,发表于《植物科学前沿》2019年第10卷9月号,第1-16页。
- [21] J. A. Gibbs、A. J. Burgess、M. P. Pound、T. P. Pridmore 和 E. H. Murchie 合著的《通过深度学习与多目标跟踪恢复密集田间环境中的风致植物运动》一文,发表于《植物生理学》2019年9月刊第181卷第1期,页码28-42。
- [22] A. 米利奥托, P. Lottes与C. Stachniss合著的《基于CNN背景知识的精准农业机器人作物与杂草实时语义分割》(2017年)。
- [23] J. Ubbens、M. Cieslak、P. Prusinkiewicz 和 I. Stavness,《植物模型在深度学习中的应用:以莲座植物叶片计数为例》,《植物方法》第14卷第1期,2018年1月。
- [24] J. Anderegg、K. Yu、H. Aasen、A. Walter、F. Liebisch 和 A. Hund,《利用光谱植被指数追踪不同小麦种质资源的衰老动态》,《植物科学前沿》第10卷,第1749页,2020年1月。
- [25] X. Jin、S. Madec、D. Dutartre、B. de Solan、A. Comar 和 F. Baret,《通过茎秆特征的高通量测量估算穗密度与地上生物量》,《植物表型组学》,2019年,第4820305页,2019年5月。
- [26] J. Brooks,《COCO注释器》,2019年。
- [27] S. Ghosal、B. Zheng、S. C. Chapman、A. B. Potgieter、D. R. Jordan、X. Wang、A. K. Singh、A. Singh、M. Hirafuji、S. Ninomiya、B. Ganapathysubramanian、S. Sarkar与W. Guo合著的《高粱穗检测与计数的弱监督深度学习框架》,发表于《植物表型组学》2019年第2019卷第1-14页。
- [28] J. Redmon 和 A. Farhadi,《YOLOv3:渐进式改进》,2018年4月。
- [29] H. Scharr, M. Minervini, A. Fischbach 和 S. A. Tsafaris,“莲座植物的注释图像数据集,”第1-16页,2014年。
- [30] 内山英树、樱井俊介、三岛正史、有田大作、冈安孝、岛田敦和谷口凛一郎,《一种易于搭建的3D表型分析平台用于紫苏数据集》,《ICCV植物表型计算机视觉问题研讨会论文集》,第2038-2045页,2017年。
- [31] M. P. 庞德、J. A. 阿特金森、D. M. 威尔斯、T. P. 普里德莫尔与A. P. 弗伦奇,《深度学习在多任务植物表型分析中的应用》,载于《IEEE国际计算机视觉研讨会论文集》,第2055-2063页,2017年
- [32] I. Sa、M. Popovic、R. Khanna、Z. Chen、P. Lottes、F. Liebisch、J. Nieto、C. Stachniss、A. Walter与R. Siegwart, R.,《杂草图谱:基于航空多光谱成像与深度神经网络的精准农业大规模语义杂草测绘框架》,《遥感》,10(9),1423,2018
- [33] N. Teimouri、M. Dyrmann、P. R. Nielsen、S. K. Mathiasen、G. J. Somerville和R. N. Jørgensen 合著的《基于深度卷积神经网络的杂草生长阶段评估方法》,发表于《传感器》2018年第18卷第5期第1580页。
- [34] S. 斯科夫森、M. 迪尔曼、A. K. 莫滕森、M. S. 劳森、R. 吉斯勒姆、J. 埃里克森、S. 法尔卡尼、H. 卡斯托夫特与R. N. 约尔根森合著的《用于农业语义与层级物种理解的草 Clover 图像数据集》,收录于《IEEE 计算机视觉与模式识别研讨会论文集》2019年版
- [35] 吴伟、郑斌、A. B. 波特吉特、J. 迪奥特、K. 渡边K、野下D. R.、乔丹X、王X、沃森J、二宫S、查普曼S. C.合著的《航空影像分析——高粱穗外观与数量的量化方法及其在育种与农学中的应用》,发表于《植物科学前沿》2018年第9卷第1544页。
- [36] 熊H、曹Z、卢H、马德C、刘S、沈C,《TasselNetv2:基于上下文增强局部回归网络的小麦穗田间计数》,《植物方法》2019年第15卷第1期。
- [37] N. Hani、P. Roy与V. Isler合著的《MinneApple:苹果检测与分割基准数据集》,发表于《IEEE机器人与自动化快报》2020年4月第5卷第2期,第852-858页。

[38] T.Y.林、M.马尔、S.贝隆吉、J.海斯、P.佩罗纳、D.拉马南、P.多勒、C.L.齐特尼克，《微软COCO：上下文中的通用对象》，载于《计算机科学讲义》（含《人工智能讲义》与《生物信息学讲义》系列），第8693卷 LNCS 第5部分，第740-755页，2014年

[39] A. 库兹涅佐娃、H. 罗姆、N. 阿尔德林、J. 乌伊林斯、I. 克拉辛、J. 普昂-图塞特、S. 卡马利、S. 波波夫、M. 马洛奇、A. 科列斯尼科夫、T. 杜林和 V. 法拉利，《开放图像数据集V4：大规模统一图像分类、目标检测与视觉关系检测》，《国际计算机视觉杂志》，2018年11月。

- [40] P. R. L. De Almeida、L. S. Oliveira、A. S. Britto、E. J. Silva 和 A. L. Koerich, 《PKLot-A: 停车场分类的稳健数据集》, 《专家系统应用》, 第42卷, 第11期, 第4937–4949页, 2015年7月。
- [41] 谢明仁、林永亮与许伟宏, 《基于无人机的空间正则化区域提议网络目标计数》, IEEE国际计算机视觉会议论文集, 2017年10月, 第4165–4173页, 2017年7月。
- [42] E. Goldman、R. Herzig、A. Eisenschat、J. Goldberger 和 T. Hassner, 《密集场景中的精确检测》, 载于《IEEE计算机学会计算机视觉与模式识别会议论文集》, 2019年6月, 第5222–5231页, 2019年
- [43] C. Pommier、C. Michotey、G. Cornut、P. Roumet、E. Duchene、R. Flores、A. Lebreton、M. Alaux、S. Durand 和 E. Kimmel 《将FAIR原则应用于GnpIS植物表型数据管理》。《植物表型组学》2019: 1671403,2019
- [44] H. Cwiek-Kupczynska、T. Altmann、D. Arend、E. Arnaud、D. Chen、G. Cornut、F. Fiorani、W. Frohmberg、A. Junker与C. Klukas合著的《表型数据互操作性评估标准：最小信息要求与格式规范》, 载于《植物方法》2016年第12卷第1期第44页。
- [45] Y. Xiang、W. Choi、Y. Lin 和 S.萨瓦雷塞, 《基于子类感知的卷积神经网络在目标提议与检测中的应用》, 载于《2017年IEEE Computer Vision 应用 Winter Conference 论文集》, WACV 2017年, 第924–933页, 2017年
- .